[illegible] №31

notes

S – размерность изображения, кр. 16.

B – размер батча

Вход: $B \times 3 \times S \times S$

FP32

eval()

из условия: 1 mult-acc = 2 Flops

сравнения в учёт операций не входят.

C_{in} – кол-во каналов на входе

C_{out} – кол-во каналов на выходе

K – размер фильтра

H_{out} – высота выхода слоя

W_{out} – ширина выхода слоя

F_i – кол-во операций слоя i для всего батча.

формула для слоя

$$F_i = \underbrace{B \cdot C_{out} H_{out} W_{out}}_{\text{число выходных чисел.}} \cdot \underbrace{2 C_{in} K^2}_{\text{операций на одно число}}$$

тогда для первой свертки

$$F_1 = B \cdot 32 \cdot \underbrace{\frac{S}{2} \cdot \frac{S}{2}}_{S/4 \text{ – выходное разрешение}} \cdot 2 \cdot 3 \cdot 7^2 \Rightarrow$$

$\Rightarrow$ $F_1 = 2352\, BS^2$ FLOPs

$$F_2 = B \cdot 64 \cdot \underbrace{\frac{S}{4} \cdot \frac{S}{4}}_{\text{уменьшилось из-за max pool}} \cdot 32 \cdot 2 \cdot 5^2 \Rightarrow$$

$\Rightarrow$ $F_2 = 6400\, BS^2$ FLOPs

$$F_3 = B \cdot 128 \cdot \frac{S}{8} \cdot \frac{S}{8} \cdot 2 \cdot 64 \cdot 3^2 =$$

$$= 2304\, BS^2 \text{ FLOPs}$$

$$F_4 = B \cdot 256 \cdot \frac{S}{8} \cdot \frac{S}{8} \cdot 2 \cdot 128 \cdot 1^2 =$$

$$= 1024\, BS^2 \text{ FLOPs}$$

$$F_5 = 2 \cdot B \cdot \frac{S}{16} \cdot \frac{S}{16} \cdot 256 \cdot 256 \cdot 3^2 =$$

$$= 4608\, BS^2 \text{ FLOPs}$$

~~$F_6 = 2 \cdot B \cdot \frac{S}{16}$~~ ~~$= 16$~~

$F_6 = 2 \cdot B \cdot \frac{S}{16}$

$= 102$

Global Avg P

на входе

размерам

GAP зам

средним зн

получаем

для средн

n−1 сло

= n оп

итог F_{poo}

~~$F_6 = 2 \cdot B \cdot \frac{S}{16} \cdot \frac{S}{16} \cdot 512 \cdot 256 \cdot 1^2 =$~~

$$F_6 = 2 \cdot B \cdot \frac{S}{16} \cdot \frac{S}{16} \cdot 512 \cdot 256 \cdot 1^2 =$$

$$= 1024\, BS^2 \text{ FLOPs}$$

Global Avg Pool

на входе тут 512 каналов
размерам S/16 × S/16

GAP заменяет каждый канал средним значением его элементов.

получаем 512 чисел. $n = \left(\frac{S}{16}\right)^2$
для среднего делаем
$n-1$ сложений + 1 деление =
= n операций.

итог $F_{pool} = B \cdot 512\, n = 2BS^2$

У линейного слоя:
каждое выходное число
исп. все входные числа.

$$512 \xrightarrow{\textcircled{?}} 256$$

с учетом bias

$$F_{Linear\,I} = B \cdot 256 \cdot (2 \cdot 512 + 1) =$$
$$= 262400\,B$$

ReLU считаем 0 FLOPs

$$F_{Linear\,II} = B \cdot 100 \cdot (2 \cdot 256 + 1) =$$
$$= 51300\,B$$

Итого:

$$F(S, B) = 17712\,BS^2 +$$
$$+ 2BS^2 + 262400B +$$
$$+ 51300\,B =$$
$$= \boxed{17714\,BS^2 + 313700\,B}$$

Расчёт пиковой памяти.
- это наибольшее кол-во одновр. занятой памяти в момент прохода сети.

$M(S,B)$ – память в байтах.

Число параметров свертки:

$$C_{out} \cdot C_{in} \cdot k^2$$

(Bias у нас в свертках нет)

для Linear: вес пары вход-выход + ~~bias~~ bias.

F_1: $32 \cdot 3 \cdot 7^2 = 4704$

F_2: $64 \cdot 32 \cdot 5^2 = 51200$

F_3: $128 \cdot 64 \cdot 3^2 = 73728$

F_4: $256 \cdot 128 \cdot 1^2 = 32768$

F_5: $256 \cdot 256 \cdot 3^2 = 589824$

F_6: $512 \cdot 256 \cdot 1^2 = 131072$

Lin_1: $512 \cdot 256 + 256 = 131328$

Lin_2: $256 \cdot 100 + 100 = 25700$

→

тогда параметров всего:

1040324

FP32 — 32 бита на число
(4 байта)

$M_{params} = 4 \cdot 1040324 = 4161296$ байт

исходный вход остается в памяти:

$4 \cdot B \cdot 3 \cdot S^2 = 12BS^2$ байт

после conv1 $\Rightarrow$ $4B \cdot 32 \cdot (S/2)^2 =$

$= 32BS^2$ байт

после maxpool:

$4B \cdot 32 \cdot (S/4)^2 = 8BS^2$ байт

Вр. индекс. maxpool:

$8 \cdot B \cdot 32 (S/4)^2 = 16BS^2$ байт

Всего: $68BS^2$ байт

другие вершины получаются меньше:

$M(S,B) =$ ~~4164~~

$4161296 + 68BS^2$ байт

$F = B(17714S^2$

$D = 4164296+$

C - скорость вычи

Время вычисле

F/C

Время передачи

D/β

β - скорость пе

$T = \tau + ma$

τ - пост. зад

$E = pT$

$\theta = (\tau, C, \beta,$

$Latency(S, B,$

416429

$Energy(S,B,\theta) =$

$F = B(17714S^2 + 313700)$ FLOPs

$D = 4164296 +$ ~~$68BS^2$ байт~~ $380BS^2 + 8592B$

C - скорость вычислений в FLOP/с

Время вычислений:

F/C

Время передачи данных:

D/β

β - скорость передачи данных.

$T = \tau + \max(F/C ; D/\beta)$ сек.

τ - пост. затраты в сек.

$E = pT$ p - ср. мощность GPU.

$\theta = (\tau, C, \beta)$

$$\text{Latency}(S, B, \theta) = \tau + \max\left(\frac{B(17714S^2 + 313700)}{C}, \frac{4164296 + \cancel{68BS^2} + 380BS^2 + 8592B}{\beta}\right)$$

$\text{Energy}(S, B, \theta) = p[$